



IITMO

Architectural Approaches to Multimodality

Современные архитектуры нейронных сетей


Мультимодальные архитектуры — это классы моделей и вычислительных систем, которые могут одновременно принимать, обрабатывать и связывать данные из разных типов модальностей (текст, изображение, аудио, видео, сенсорные сигналы) в едином представлении, обеспечивая совместное понимание и генерацию контента.



Примеры задач:


- **Генерация изображений и видео по текстовому промπτу** (прошлая лекция)
- **OCR** (распознавание символов на изображении)
- **IQA** (Image question answering)

1. Contrastive pre-training




Supervises approach vs CLIP

Typical Supervised Approach



Contrastive Supervised Approach



CLIP loss function

```
# image_encoder - ResNet or Vision Transformer
# text_encoder - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l] - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t - temperature parameter

# 1) get a batch of aligned images and text
I, T = get_mini_batch()

# 2) extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T) #[n, d_t]

# 3) joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)


# 4) scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# 5) symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t)/2
```


$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$


$$L_{CE} = - \sum_{i=1}^n t_i \log(p_i)$$

CLIP применение: Image classification



CLIP результаты

	Dataset Examples	ImageNet ResNet101	Zero-Shot CLIP	Δ Score
ImageNet		76.2	76.2	0%
ImageNetV2		64.3	70.1	+5.8%
ImageNet-R		37.7	88.9	+51.2%
ObjectNet		32.6	72.3	+39.7%
ImageNet Sketch		25.2	60.2	+35.0%
ImageNet-A		2.7	77.1	+74.4%

CLIP применение: другие примеры



Использование 2: Поиск изображений


Аналогично тому, как мы строим классификатор изображений, мы можем передать фразу в текстовый энкодер, несколько изображений — в энкодер изображений, вычислить скалярное произведение и softmax, и таким образом получить вероятность того, какое изображение наиболее соответствует заданному тексту.

Использование 3: Энкодер изображений

Поскольку CLIP хорошо представляет содержание изображений в целом, мы можем использовать энкодер изображений для последующих задач (downstream tasks).


Использование 4: Текстовый энкодер

Поскольку CLIP хорошо понимает, какие аспекты языковой фразы важны для изображений, мы можем использовать текстовый энкодер для последующих задач.




Состоит из **Image Encoder** и **Text Encoder** – также как и CLIP
 Но во время обучения используются три loss function: **ITC**, **ITM**, **LM**

BLIP: ITC loss




Bi self-Attention vs Masked self-Attention

Unidirectional Self-Attention





Bidirectional Self-Attention



ITC loss — это тот же контрастивный лосс, который используется в CLIP.

Его цель — максимизировать сходство (скалярное произведение) эмбеддингов изображений и текстов для правильных пар и минимизировать его для несоответствующих.


BLIP: ITM loss



ITM loss — это функция потерь для задачи бинарной классификации, которая определяет, соответствует ли текст изображению.

Модель получает текстовый энкодер с кросс-аттеншеном к визуальным признакам, после чего должна выдать "match / no match".

BLIP: LM loss



LM loss — это языковая функция потерь (Language Modeling Loss), которая обучает модель генерировать корректный текст, условный на изображении.


Модель получает визуальные признаки и предшествующий текст, после чего предсказывает следующий токен в последовательности. Лосс рассчитывается как кросс-энтропия по предсказанному распределению токенов.

Подписи к изображениям: создание описаний изображений на естественном языке.

Визуальные ответы на вопросы (VQA): ответы на вопросы в свободной форме о содержании изображения.


Кросс-модальный поиск: поиск изображений на основе текстовых запросов и наоборот.

Понимание обоснованного языка: связывание слов или фраз с определенными областями на изображении.



В BLIP нужно было совместно обучать Image Encoder и LLM – что очень дорого. BLIP-2 позволяет взять два независимых Image Encoder, LLM и очень дешево сделать из них мультимодальную архитектуру. Во время обучения, обучая только **Q-former** и **вектора queries**


VLIP-2: как обучается



Q-Former – небольшой трансформер состоящий из нескольких слоёв
Learned Queries – набор векторов, которые обучаемые (по смыслу являются адаптерами между текстом и изображением)

Обучается с помощью лосов ITC, ITM, LM (тут он назван Image-Grounded Text Generation)


VLIP-2: Как применяется



Для архитектур Decoder-based (все современные LLM именно такие) полученные эмбединги от Q-Former передаются сразу в Decoder

Для архитектур Encoder-Decoder-based (как оригинальный Transformer) полученные эмбединги от Q-Former передаются сначала в Encoder блок, а потом уже в Decoder

InstructBLIP



На самом деле в задачах мультимодальности (изображение, текст) можно из декомпозировать на разные подгруппы: Image Classification, IQA, IQG и так далее.

С логической точки зрения не совсем правильно их обучать одинаково, нужно из разделять

InstructBLIP: Собрали датасет и разделили его




Dataset Name	Held-out	Dataset Description
COCO Caption [23]	✗	We use the large-scale COCO dataset for the image captioning task. Specifically, Karpathy split [17] is used, which divides the data into 82K/5K/5K images for the train/val/test sets.
Web CapFilt	✗	14M image-text pairs collected from the web with additional BLIP-generated synthetic captions, used in BLIP [21] and BLIP-2 [20].
NoCaps [3]	✓ (val)	NoCaps contains 15,100 images with 166,100 human-written captions for novel object image captioning.
Flickr30K [51]	✓ (test)	The Flickr30k dataset consists of 31K images collected from Flickr, each image has five ground truth captions. We use the test split as the held-out which contains 1K images.
TextCaps [38]	✗	TextCaps is an image captioning dataset that requires the model to comprehend and reason the text in images. Its train/val/test sets contain 21K/3K/3K images, respectively.
VQAv2 [11]	✗	VQAv2 is dataset for open-ended image question answering. It is split into 82K/40K/81K for train/val/test.
VizWiz [12]	✓ (test-dev)	A dataset contains visual questions asked by people who are blind. 8K images are used for the held-out evaluation.
GQA [16]	✓ (test-dev)	GQA contains image questions for scene understanding and reasoning. We use the balanced test-dev set as held-out.
Visual Spatial Reasoning	✓ (test)	VSR is a collection of image-text pairs, in which the text describes the spatial relation of two objects in the image. Models are required to classify true/false for the description. We use the zero-shot data split given in its official github repository.
IconQA [29]	✓ (test)	IconQA measures the abstract diagram understanding and comprehensive cognitive reasoning abilities of models. We use the test set of its multi-text-choice task for held-out evaluation.
OKVQA [30]	✗	OKVQA contains visual questions that require outside knowledge to answer. It has been split into 9K/5K for train and test.
A-OKVQA [36]	✗	A-OKVQA is a successor of OKVQA with more challenging and diverse questions. It has 17K/1K/6K questions for train/val/test.
ScienceQA [28]	✓ (test)	ScienceQA covers diverse science topics with corresponding lectures and explanations. In out settings, we only use the part with image context (IMG).
Visual Dialog [8]	✓ (val)	Visual dialog is a conversational question answering dataset. We use the val split as the held-out, which contains 2,064 images and each has 10 rounds.
OCR-VQA [31]	✗	OCR-VQA contains visual questions that require models to read text in the image. It has 800K/100K/100K for train/val/test, respectively.
TextVQA [39]	✓ (val)	TextVQA requires models to comprehend visual text to answer questions.
HatefulMemes [18]	✓ (val)	A binary classification dataset to justify whether a meme contains hateful content.
LLaVA-Instruct-150K [25]	✗	An instruction tuning dataset which has three parts: detailed caption (23K), reasoning (77K), conversation (58K).
MSVD-QA [47]	✓ (test)	We use the test set (13K video QA pairs) of MSVD-QA for held-out testing.
MSRVTT-QA [47]	✓ (test)	MSRVTT-QA has more complex scenes than MSVD, with 72K video QA pairs as the test set.
iVQA [49]	✓ (test)	iVQA is a video QA dataset with mitigated language biases. It has 6K/2K/2K samples for train/val/test.

InstructBLIP: Подготовили свой шаблон на задачу



Task	Instruction Template
Image Captioning	<Image>A short image caption: <Image>A short image description: <Image>A photo of <Image>An image that shows <Image>Write a short description for the image. <Image>Write a description for the photo. <Image>Provide a description of what is presented in the photo. <Image>Briefly describe the content of the image. <Image>Can you briefly explain what you see in the image? <Image>Could you use a few words to describe what you perceive in the photo? <Image>Please provide a short depiction of the picture. <Image>Using language, provide a short account of the image. <Image>Use a few words to illustrate what is happening in the picture.
VQA	<Image>{ Question} <Image>Question: { Question} <Image>{ Question} A short answer to the question is <Image>Q: { Question} A: <Image>Question: { Question} Short answer: <Image>Given the image, answer the following question with no more than three words. { Question} <Image>Based on the image, respond to this question with a short answer: { Question}. Answer: <Image>Use the provided image to answer the question: { Question} Provide your answer as short as possible: <Image>What is the answer to the following question? "{ Question}" <Image>The question "{ Question}" can be answered using the image. A short answer is
VQG	<Image>Given the image, generate a question whose answer is: { Answer}. Question: <Image>Based on the image, provide a question with the answer: { Answer}. Question: <Image>Given the visual representation, create a question for which the answer is "{ Answer}". <Image>From the image provided, craft a question that leads to the reply: { Answer}. Question: <Image>Considering the picture, come up with a question where the answer is: { Answer}. <Image>Taking the image into account, generate an question that has the answer: { Answer}. Question:

InstructBLIP



Использовали ту же самую архитектуру, что и BLIP2 с единственным отличием

Инструкцию (шаблон) передавали в Q-Former и LLM


InstructBLIP: Результаты



	NoCaps	Flickr 30K	GQA	VSR	IconQA	TextVQA	Visdial	HM	VizWiz	SciQA image	MSVD QA	MSRVTT QA	iVQA
Flamingo-3B [4]	-	60.6	-	-	-	30.1	-	53.7	28.9	-	27.5	11.0	32.7
Flamingo-9B [4]	-	61.5	-	-	-	31.8	-	57.0	28.8	-	30.2	13.7	35.2
Flamingo-80B [4]	-	67.2	-	-	-	35.0	-	46.4	31.6	-	35.6	17.4	40.7
BLIP-2 (FlanT5 _{XL}) [20]	104.5	76.1	44.0	60.5	45.5	43.1	45.7	53.0	29.8	54.9	33.7	16.2	40.4
BLIP-2 (FlanT5 _{XXL}) [20]	98.4	73.7	44.6	68.2	45.4	44.1	46.9	52.0	29.4	64.5	34.4	17.4	45.8
BLIP-2 (Vicuna-7B)	107.5	74.9	38.6	50.0	39.7	40.1	44.9	50.6	25.3	53.8	18.3	9.2	27.5
BLIP-2 (Vicuna-13B)	103.9	71.6	41.0	50.9	40.6	42.5	45.1	53.7	19.6	61.0	20.3	10.3	23.5
InstructBLIP (FlanT5 _{XL})	119.9	84.5	48.4	64.8	50.0	46.6	46.6	56.6	32.7	70.4	43.4	25.0	53.1
InstructBLIP (FlanT5 _{XXL})	120.0	83.5	47.9	65.6	51.2	46.6	48.5	54.1	30.9	70.6	44.3	25.6	53.8
InstructBLIP (Vicuna-7B)	123.1	82.4	49.2	54.3	43.1	50.1	45.2	59.6	34.5	60.5	41.8	22.1	52.2
InstructBLIP (Vicuna-13B)	121.9	82.8	49.5	52.1	44.8	50.7	45.4	57.5	33.4	63.1	41.2	24.8	51.0

Zero-shot (без обучения) на разных задачах


Grounding DINO: Zero-shot object detection




Позволяет детектировать объекты базируясь на тексте

Grounding DINO: FEL

2. A Feature Enhancer Layer




Deformable Self-Attention



Связывает Image и Text Features через серию Cross Attention

Grounding DINO: Decoder layer



После второго этапа выбираются TopK queries (это кандидаты на то, что в этом патче может что-то быть)

И делается еще одна процедура с Cross Attention

Grounding DINO: inference

Input: Image-Text Pair

Two dogs with a stick .



Grounding
DINO



Output: a list of (box, text similarity scores)



0.5 0.6 0.0 0.0 0.1 0.0
Two dogs with a stick .



0.6 0.7 0.0 0.0 0.1 0.0
Two dogs with a stick .



0.1 0.0 0.0 0.0 0.8 0.0
Two dogs with a stick .




0.1 0.0 0.0 0.0 0.1 0.0
Two dogs with a stick .

...

(a) For Caption Inputs

Yolo-World



```
from ultralytics import YOLO


# Initialize a YOLO-World model
model = YOLO("yolov8s-world.pt") # or choose yolov8m/l-world.pt

# Define custom classes
model.set_classes(["person", "bus"])


# Execute prediction for specified categories on an image
results = model.predict("path/to/image.jpg")

# Show results
results[0].show()
```

SAM: Zero-shot image segmentation



SAM: Mask decoder



Key: what we have
Query: what we are looking for
Value: what we want to propagate

SAM: SA-1B датасет для обучения



Описание набора данных

- **SA-1B** — датасет из **11 млн изображений** высокого разрешения.
- Содержит **~1,1 млрд масок** (самый крупный набор сегментации в истории).
- Финальное разрешение изображений: **1500 px по короткой стороне** (исходная версия: ~3300 × 4950 px).
- Маски на изображение: от **<50 до >500**.
- Отличается высокой вариативностью сцен и объектов.

1. Ручной этап (Human-in-the-Loop)

- Профессиональные разметчики использовали раннюю версию SAM.
- Отмечали самые заметные объекты; ограничение — 30 секунд на изображение.
- После этапа модель повторно обучили.
- **120 тыс. изображений, 4,3 млн масок.**


2. Полуавтоматический этап

- SAM генерирует часть масок автоматически.
- Разметчики добавляют недостающие/малозаметные объекты.
- Модель снова переобучена на расширенном наборе.
- **300 тыс. изображений, 10,2 млн масок.**


3. Полностью автоматический этап

- Процесс аннотирования полностью автоматизирован.
- SAM получает сетку **32×32 точек** для генерации масок.
- Применена постобработка для повышения качества.

Whisper: Voice to Text



GPT-4o architecture?



Нет достоверно известной информации какая архитектура у GPT-4o (Умеет понимать картинки, голос, текст и на выходе генерировать изображения или выдавать текст)

Но скорее всего работает схожим образом как у BLIP – есть отдельные кодировщики модальностей, информация от которых затем поступает для дальнейшего совместного анализа

- 1) Мультимодальность — ключевое направление развития моделей ИИ.
- 2) Совместное обучение на разных модальностях улучшает качество даже на одной модальности.
- 3) Объединённые представления позволяют моделям строить более глубокие семантические связи.
- 4) Полноценные мультимодальные модели требуют огромных данных и ресурсов (CLIP, BLIP, GPT-4o).
- 5) Есть облегчённые варианты: можно обучать только коннектор между модальностями (BLIP-2, InstructBLIP).
- 6) Мультимодальность критична для задач генерации изображений, видео, аудио, VQA, OCR, captioning, grounding.
- 7) Будущее — единые модели, которые принимают и генерируют текст, изображение, аудио и видео в одном трансформере.

**Спасибо
за внимание!**

it'sMO *re than a*
UNIVERSITY